

ĐỀ XUẤT HƯỚNG NGHIÊN CỨU

Sinh đặc trưng tài chính từ báo cáo tài chính tiếng Việt bằng mô hình ngôn ngữ

1. BỐI CẢNH

1.1. Lĩnh vực hẹp

Sinh đặc trưng tự động từ báo cáo tài chính bằng mô hình ngôn ngữ quy mô nhỏ, phục vụ bài toán xếp hạng cổ phiếu theo lát cắt ngang, chân trời dự báo hàng tháng đến hàng quý.

1.2. Thực trạng nghiên cứu

Nhánh khai phá nhân tố bằng mô hình ngôn ngữ lớn hiện rất đông. Riêng giai đoạn 2025 đến 2026 đã có AlphaCrafter, AlphaAgent, RD-Agent, QuantAgent, Alpha-GPT, CogAlpha, FactorMAD và AlphaMemo. Trong đó AlphaCrafter công bố tháng 5 năm 2026 là hệ thống đa tác tử ba tầng.

Tuy nhiên, toàn bộ các hệ thống này đều sử dụng mô hình frontier thông qua giao diện lập trình. AlphaCrafter sử dụng Claude Opus 4.6; nhóm Kou và cộng sự sử dụng GPT-4o. Không công trình nào đặt câu hỏi ngược lại: có thực sự cần mô hình quy mô nghìn tỷ tham số cho nhiệm vụ này hay không.

Đồng thời, kết quả của cả nhánh đang bị đặt dấu hỏi. Khung đánh giá FINSABER kiểm định lại trên hai thập kỷ và hơn 100 mã cổ phiếu, kết luận rằng lợi thế mà các công trình trước báo cáo suy giảm đáng kể khi mở rộng phạm vi và kéo dài thời gian đánh giá. Đã hình thành một dòng công cụ chuyên đo rò rỉ thông tin gồm Look-Ahead-Bench, DatedGPT và phương pháp ẩn danh hóa.

Với tiếng Việt, mảng nghiên cứu còn mỏng và một chiều. Các công trình hiện có đều sử dụng PhoBERT cho phân loại cảm xúc tin tức báo chí. Một nghiên cứu công bố năm 2023 sử dụng gần 40.000 bài báo, đạt độ chính xác trên 81%, nhưng kết luận phản ứng của giá đối với tin tức là không đáng kể. Chưa có công trình nào khai thác báo cáo tài chính.

2. KHOẢNG TRỐNG NGHIÊN CỨU

2.1. Khoảng trống thứ nhất: chưa kiểm chứng ngưỡng quy mô mô hình cần thiết

Toàn bộ các hệ thống khai phá nhân tố bằng mô hình ngôn ngữ đều mặc định phải sử dụng mô hình frontier. Giả định này chưa từng được kiểm chứng, trong khi có ba bằng chứng độc lập cho thấy nó có thể sai:

Nguồn	Bằng chứng
Xiao và cộng sự (2025)	Bộ truy xuất FinSeer 109 triệu tham số đánh bại mô hình E5 7 tỷ tham số trên cả ba tập dữ liệu. Kết luận: chuyên biệt hóa theo lĩnh vực thắng dung lượng mô hình
Valeyre và Aboura (2024)	Mô hình Chronos-tiny 11 triệu tham số ở chế độ zero-shot đạt tỷ số Sharpe 3,17 trước chi phí, tương đương các phương pháp phức tạp hơn nhiều
Nghiên cứu NLP tiếng Việt	PhoBERT 135 triệu tham số đạt macro-F1 74,93%, trong khi GPT-4 ở chế độ zero-shot chỉ đạt 60,14% trên cùng tác vụ

Phát biểu khoảng trống: Chưa có công trình nào so sánh hệ thống sinh đặc trưng tài chính sử dụng mô hình ngôn ngữ quy mô nhỏ tự triển khai với hệ thống sử dụng mô hình frontier qua giao diện lập trình, trên cùng dữ liệu, cùng giao thức đánh giá và có tính đến chi phí vận hành.

Ưu điểm nếu giải quyết

- Nếu mô hình nhỏ đạt kết quả tương đương, kết quả có ý nghĩa thực tiễn lớn, vì chi phí truy vấn là rào cản thật đối với tổ chức nhỏ và cá nhân.
- Nếu mô hình nhỏ thua rõ rệt, nghiên cứu xác định được ngưỡng quy mô tối thiểu cho nhiệm vụ này, cũng là kết quả chưa ai đo.
- Không phụ thuộc giao diện lập trình: chi phí bằng không, không bị giới hạn truy vấn, và không lo nhà cung cấp cập nhật mô hình ngầm làm mất tính tái lập của thí nghiệm.

Thách thức

- Mô hình nhỏ có thể sinh công thức sai cú pháp hoặc vô nghĩa với tần suất cao hơn. Cần cơ chế kiểm tra tự động kết hợp khâu chuyên gia duyệt.
- Cần đánh giá và lựa chọn mô hình sinh tiếng Việt phù hợp trong ràng buộc phần cứng.

2.2. Khoảng trống thứ hai: chưa khai thác báo cáo tài chính tiếng Việt

Đã có trong tài liệu tiếng Việt	Chưa có
PhoBERT phân loại cảm xúc tin tức báo chí	Đọc và khai thác báo cáo tài chính
Dự báo giá ngày kế tiếp	Sinh đặc trưng hoặc công thức
LSTM-Attention trên chuỗi giá	Mô hình nhân tố

Báo cáo tài chính là nguồn dữ liệu có cấu trúc ngữ nghĩa sâu hơn tin tức báo chí và chưa được khai thác cho tiếng Việt.

Phát biểu khoảng trống: Chưa có công trình nào khai thác nội dung báo cáo tài chính doanh nghiệp niêm yết Việt Nam bằng mô hình ngôn ngữ để sinh đặc trưng cho mô hình nhân tố.

Giá trị bổ sung: thí nghiệm tự nhiên

Nhánh nghiên cứu quốc tế đang tốn nhiều công sức để giả lập điều kiện mô hình không biết trước kết quả, thông qua DatedGPT huấn luyện lại theo mốc thời gian, phương pháp ẩn danh hóa xóa tên doanh nghiệp, và dòng mô hình Point-in-Time thương mại.

Dữ liệu tiếng Việt cung cấp điều kiện đó một cách tự nhiên, do mô hình ngôn ngữ kể cả frontier gần như không có dữ liệu báo cáo tài chính doanh nghiệp Việt Nam trong tập huấn luyện. Đây là biến thiên ngoại sinh mà thị trường Hoa Kỳ và Trung Quốc không thể cung cấp.

3. ĐỀ XUẤT BÀI TOÁN

3.1. Phát biểu bài toán

Xây dựng hệ thống sinh đặc trưng tài chính tường minh từ báo cáo tài chính tiếng Việt, sử dụng mô hình ngôn ngữ quy mô nhỏ tự triển khai, có khâu chuyên gia duyệt và có kiểm soát rò rỉ thông tin; đánh giá đối chứng với hệ thống sử dụng mô hình frontier.


Đầu vào

- Báo cáo tài chính của N doanh nghiệp niêm yết, theo quý, trong T năm, gồm phần bảng số và phần thuyết minh.
- Ngày công bố thực tế của từng báo cáo.
- Dữ liệu giá và khối lượng giao dịch theo ngày; mã phân ngành.

Đầu ra

- Tập công thức đặc trưng tường minh, kèm truy vết về chỉ tiêu hoặc đoạn văn nguồn.
- Xếp hạng cổ phiếu theo lát cắt ngang cho kỳ tiếp theo.
- Danh mục đầu tư và kết quả kiểm định ngược sau chi phí.

3.2. Kiến trúc hệ thống



3.3. Lựa chọn mô hình và căn cứ

Thành phần	Lựa chọn	Tham số	Căn cứ
Bộ mã hóa, truy xuất	PhoBERT-base	135 triệu	Encoder-only, đúng thể mạnh sinh vector nhúng. Hiện là mô hình tốt nhất cho tiếng Việt
Bộ sinh công thức	Cần đánh giá: Qwen2.5 1.5B	1-3 tỷ	Decoder-only, có khả năng sinh chuỗi. Chạy được trên GPU phổ thông khi lượng tử hóa

	hoặc 3B, PhoGPT, Vistral		
Mô hình nhân tố	MLP hoặc LightGBM	Khoảng 1.000	Các công trình hàng đầu đều dùng mô hình rất nhỏ: GPZ vài trăm tham số, Epstein chiều ẩn 32
Baseline đối chứng	GPT-4o hoặc Claude qua API	Rất lớn	Đại diện cách làm hiện hành của AlphaCrafter và Kou và cộng sự

Ghi chú về ràng buộc quy mô: bộ sinh công thức 1 đến 3 tỷ tham số vượt ngưỡng vài trăm triệu mà giảng viên hướng dẫn đã nêu. Đây là đánh đổi bắt buộc, do kiến trúc encoder-only không sinh được công thức, mà công thức tường minh là điều kiện của tính diễn giải. Với kỹ thuật lượng tử hóa 4 bit, mô hình 3 tỷ tham số chạy được trên card đồ họa 8GB. Nhóm đề nghị thầy xác nhận mức đánh đổi này có chấp nhận được hay không.

3.4. Các bảng kết quả cần tạo ra

Bảng 1: So sánh quy mô mô hình (kết quả chính)

Hệ thống	Tham số	Chi phí	Tỷ lệ hợp lệ	IC	Sharpe sau phí
Nhân tố thủ công (cơ sở)	—	0	—	?	?
PhoBERT + SLM 1.5B	~1,6 tỷ	Tự chạy	?	?	?
PhoBERT + SLM 3B	~3,1 tỷ	Tự chạy	?	?	?
LLM frontier qua API	Rất lớn	Trả phí	?	?	?

Bảng 2: Ảnh hưởng của cách gán dữ liệu

Cách gán dữ liệu	IC	Sharpe sau phí	Mức tối ưu phòng
Gán theo ngày kết thúc quý (ngây thơ)	?	?	—
Gán theo ngày công bố thực tế	?	?	?

Bảng 3: Ảnh hưởng của chi phí giao dịch

Mô hình chi phí	Tỷ số Sharpe
Không tính phí	?
Phí cố định theo chuẩn quốc tế (5 điểm cơ bản)	?
Phí thực tế thị trường Việt Nam	?

4. XỬ LÝ HAI RỦI RO BỊ TỪ CHỐI

4.1. Rủi ro bị bất lỗi kiến trúc mô hình

Nguyên nhân thường gặp là gán sai vai trò giữa mô hình encoder-only và decoder-only. Biện pháp phòng ngừa:

- Kiến trúc tại mục 3.2 phân vai rõ ràng, và bài báo sẽ nêu tường minh căn cứ chọn từng mô hình thay vì để người đọc tự suy đoán.
- PhoBERT chỉ làm bộ mã hóa và truy xuất, không sinh văn bản. Có tiền lệ trực tiếp là bộ truy xuất FinSeer trong Xiao và cộng sự (2025).
- Bổ sung thí nghiệm loại bỏ thành phần để chứng minh mỗi mô-đun có đóng góp thực, tránh phản biện đặt câu hỏi vì sao phải dùng hai mô hình.

4.2. Rủi ro bị bất lỗi định lượng

Đây là rủi ro nghiêm trọng hơn, và cũng là rủi ro mà phần lớn công trình trong nhánh đều mắc phải.

a) Rò rỉ dữ liệu tại thời điểm

- Thu thập ngày công bố thực tế, không sử dụng ngày kết thúc kỳ báo cáo.
- Xử lý các trường hợp dính chính theo nguyên tắc của Wei và cộng sự (2022).
- Trình bày Bảng 2 như một kết quả độc lập, biến việc kiểm soát thành đóng góp thay vì chỉ là thủ tục.

b) Rò rỉ qua mốc dữ liệu huấn luyện của mô hình ngôn ngữ

- Lợi thế của mô hình tự triển khai: mốc dữ liệu huấn luyện được biết chính xác và cố định, khác với mô hình qua giao diện lập trình có thể được cập nhật ngầm.
- Áp dụng nguyên tắc cách ly: chỉ sử dụng mô hình ngôn ngữ để sinh công thức, không sử dụng để lựa chọn phụ thuộc thời điểm. Việc lựa chọn do kiểm định trên dữ liệu trước thời điểm đánh giá quyết định.
- Tham chiếu các khung đã có gồm Look-Ahead-Bench, DatedGPT và phương pháp ẩn danh hóa.

c) Chi phí giao dịch và trượt giá

Đây là điểm nhóm có thể tạo khác biệt rõ nhất, do chi phí giao dịch tại Việt Nam cao hơn nhiều lần so với mức 5 điểm cơ bản mà các công trình quốc tế sử dụng. Các thành phần cần đưa vào mô hình chi phí:

- Phí môi giới mỗi chiều giao dịch.
- Thuế thu nhập khi bán, áp trên giá trị bán và không phụ thuộc lãi lỗ.
- Chênh lệch giá mua bán, cao hơn đáng kể với cổ phiếu thanh khoản thấp.
- Tác động thị trường, thành phần mà chưa công trình nào trong số đã khảo sát mô hình hóa.

Riêng việc trình bày Bảng 3 đã là một đóng góp, do Valeyre và Aboura đã chứng minh chỉ với mức trượt giá 3 điểm cơ bản, tỷ số Sharpe giảm từ dương 3,17 xuống âm 1,49. Với mức phí thực tế của thị trường Việt Nam, câu hỏi này càng gay gắt hơn.

d) Kiểm định thống kê

- Báo cáo t-statistic và sai số chuẩn, không chỉ báo cáo điểm ước lượng.
- Phân tích kết quả theo giai đoạn con.
- Nêu rõ số lượng công thức đã thử nghiệm và áp dụng hiệu chỉnh kiểm định đa giả thuyết.

5. DỮ LIỆU VÀ TÍNH KHẢ THI

5.1. Nguồn dữ liệu

Nguồn	Nội dung	Trạng thái
Cần điền	Báo cáo tài chính doanh nghiệp niêm yết	Đã có nguồn, chưa tải về
vnstock hoặc API công ty chứng khoán	Giá và khối lượng theo ngày	Chưa thu thập
HOSE và HNX	Ngày công bố thông tin	Chưa kiểm tra có sẵn hay không
HuggingFace	PhoBERT và các mô hình sinh tiếng Việt	Công khai, miễn phí

5.2. Khối lượng dữ liệu

Đây là rủi ro lớn nhất hiện tại và cần được xác nhận trước khi triển khai.

Chỉ tiêu	Hiện trạng	Yêu cầu tối thiểu
Số doanh nghiệp	Chưa rõ	Khoảng 200 để lát cắt ngang đủ rộng
Số năm dữ liệu	Chưa rõ	Khoảng 10 năm
Tần suất dữ liệu giá	Mới có theo tháng hoặc quý	Cần bổ sung theo ngày

Vấn đề số quan sát: với dữ liệu theo quý, mười năm chỉ cho khoảng 40 điểm thời gian. Sau khi chia thành tập huấn luyện, tập kiểm tra và tập đánh giá thì tập đánh giá chỉ còn khoảng 10 điểm, quá mỏng để rút ra kết luận thống kê.

Giải pháp đề xuất là bổ sung dữ liệu giá theo tần suất ngày, tương ứng khoảng 2.500 điểm, nhằm tăng số quan sát huấn luyện, trong khi vẫn tái cân bằng danh mục theo tháng hoặc quý. Nhóm Wei và cộng sự (2022) áp dụng đúng cách này.

5.3. Yêu cầu tính toán

6. CÁC VẤN ĐỀ CẦN THẦY TƯ VẤN

Về kiến trúc

- Bộ sinh công thức cần mô hình 1 đến 3 tỷ tham số, vượt ngưỡng vài trăm triệu mà thầy đã nêu. Đây là đánh đổi bắt buộc để giữ tính diễn giải. Thầy có chấp nhận hay nên chuyển sang phương án trích xuất vector nhúng, tức là mất tính diễn giải nhưng đúng ràng buộc?
- Có nên bỏ hẳn nhánh xử lý văn bản và chỉ sử dụng chỉ tiêu tài chính có cấu trúc, nhằm giảm độ phức tạp không?

Về phạm vi

- Việc gộp ba nội dung gồm so sánh quy mô mô hình, kiểm soát rò rỉ thông tin và mô hình chi phí giao dịch Việt Nam có quá tải cho một đồ án không? Nếu cần tách, nên giữ nội dung nào làm chính?
- Có nên giới hạn phạm vi ở một nhóm ngành để giảm độ phức tạp không?

Về dữ liệu

- Nguồn nào tại Việt Nam lưu ngày công bố thực tế của báo cáo tài chính? Đây là điều kiện tiên quyết của nội dung kiểm soát rò rỉ dữ liệu.
- Với dữ liệu theo quý, số điểm thời gian rất ít. Phương án bổ sung dữ liệu giá theo ngày có hợp lý không?

Về đánh giá

- Mức chi phí giao dịch nào là hợp lý để mô phỏng cho thị trường Việt Nam?
- Khâu chuyên gia duyệt công thức nên do nhóm tự đảm nhiệm hay cần mời người có chuyên môn thực tế?

Thành phần	Yêu cầu
Tinh chỉnh PhoBERT	Một card đồ họa phổ thông
Suy luận mô hình sinh 1–3 tỷ tham số	Một card đồ họa 8GB với lượng tử hóa 4 bit
Mô hình nhân tố	Chạy được trên CPU
Baseline qua API	Chi phí truy vấn, ước tính thấp

Để đối chiếu, nhóm Valeyre và Aboura tinh chỉnh mô hình Chronos 11 triệu tham số trên hai card RTX 4060 Ti trong khoảng một tuần. Quy mô tính toán của đề tài này tương đương hoặc nhẹ hơn.

TÀI LIỆU THAM KHẢO CHÍNH

[1] Wei, Z., Dai, B., Lin, D. (2022). Factor Investing with a Deep Multi-Factor Model. arXiv:2210.12462.

[2] Xiao, M., Jiang, Z., Qian, L., et al. (2025). Retrieval-augmented Large Language Models for Financial Time Series Forecasting. arXiv:2502.05878.

[3] Valeyre, S., Aboura, S. (2024). LLMs for Time Series: an Application for Single Stocks and Statistical Arbitrage. arXiv:2412.09394.

[4] Kou, Z., Yu, H., Luo, J., et al. (2025). Automate Strategy Finding with LLM in Quant Investment. arXiv:2409.06289.

[5] AlphaCrafter: A Full-Stack Multi-Agent Framework for Cross-Sectional Quantitative Trading (2026). arXiv:2605.05580.

[6] Can LLM-based Financial Investing Strategies Outperform the Market in Long Run? (FINSABER, 2025). arXiv:2505.07078.

[7] Look-Ahead-Bench: a Standardized Benchmark of Look-ahead Bias in Point-in-Time LLMs for Finance (2026). arXiv:2601.13770.

[8] Nguyen, D. Q., Nguyen, A. T. (2020). PhoBERT: Pre-trained language models for Vietnamese. Findings of EMNLP.

[9] Guijarro-Ordóñez, J., Pelger, M., Zanotti, G. (2022). Deep Learning Statistical Arbitrage. arXiv:2106.04028.

[10] Epstein, E. L., Wang, R., Choi, J., Pelger, M. (2025). Attention Factors for Statistical Arbitrage. arXiv:2510.11616.

